TDM

Desafío Ingeniero EnP Datos

Cristian Pazmiño
20 abril 2026

1 OBJETIVO

Diseño e implementación de una solución TDM funcional orientada al escaneo e identificación de datos sensibles, anonimización determinística preservando integridad referencial y creación de datos sintéticos con trazabilidad, validación y reportes de calidad.

2 ALCANCE

La solución se divide en dos modulo principales:

2.1 ANONIMIZACIÓN

- Identificación de columnas candidatas a datos sensibles mediante técnicas de muestreo y validación por reglas.
- Aplicación de anonimización determinística sobre columnas que superen un umbral configurable.
- Preservación del formato, tipo de dato y validez de los valores anonimizados.
- Mantenimiento de la integridad referencial entre entidades relacionadas.
- Generación de trazabilidad sobre las reglas aplicadas y transformaciones realizadas.

2.2 DATOS SINTÉTICOS

- Generación de datasets sintéticos de clientes (100–500 registros, parametrizable).
- Aplicación de reglas de negocio, esquema e integridad definidas en un contrato de datos.
- Inyección controlada de errores (schema, domain, duplicados y negocio) en un porcentaje parametrizable.
- Validación determinística de los datos generados, con clasificación de errores por tipo.
- Generación de reportes de calidad y perfilado de datos, incluyendo métricas de cumplimiento y muestras de error.

3 REQUERIMIENTOS

La solución deberá cumplir con los siguientes requerimientos funcionales y técnicos:

- Detección de columnas sensibles mediante muestreo y análisis de probabilidad por tipo de dato (PII/PCI).
- Clasificación de datos sensibles con base en un umbral configurable (por defecto 90%).
- Anonimización determinística y reutilizable, garantizando consistencia entre ejecuciones.
- Preservación del formato, longitud y tipo de dato de los valores anonimizados.
- Mantenimiento de la integridad referencial entre entidades relacionadas.
- Implementación de mecanismos de logging, manejo de errores e idempotencia.
- Generación de datasets sintéticos parametrizables.
- Inyección controlada de errores (schema, domain, duplicados y negocio).
- Validación determinística de datos generados, con clasificación de errores.
- Generación de reportes de calidad y métricas de cumplimiento.

4 ARQUITECTURA

La solución propuesta mantienen una arquitectura modular orientada a la escalabilidad y mantenibilidad de TDM:

ANONIMIZACIÓN

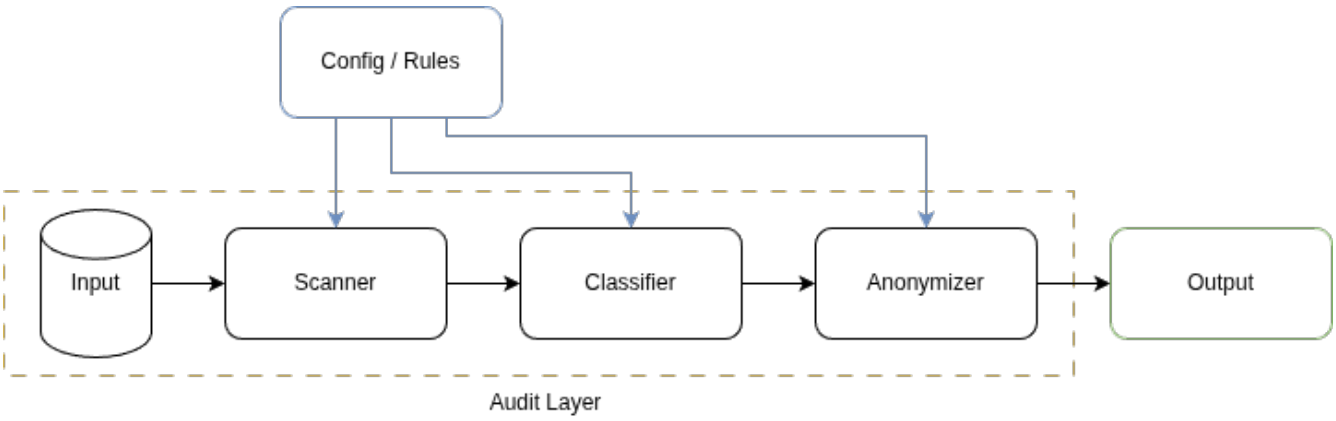

- **Input:** Conjunto de tablas relacionales de entrada (clientes, facturación, notificaciones).
- **Scanner**: Analizar columnas mediante muestreo y detectar posibles datos sensibles utilizando reglas y validaciones.
- **Classifier: C**alcula la probabilidad de que una columna pertenezca a un tipo sensible (cédula, teléfono, correo) y decide su clasificación en función de un umbral configurable.
- **Anonymizer:** Anonimización determinística sobre datos sensibles, preservando formato, validez e integridad referencial.

DATOS SINTÉTICOS

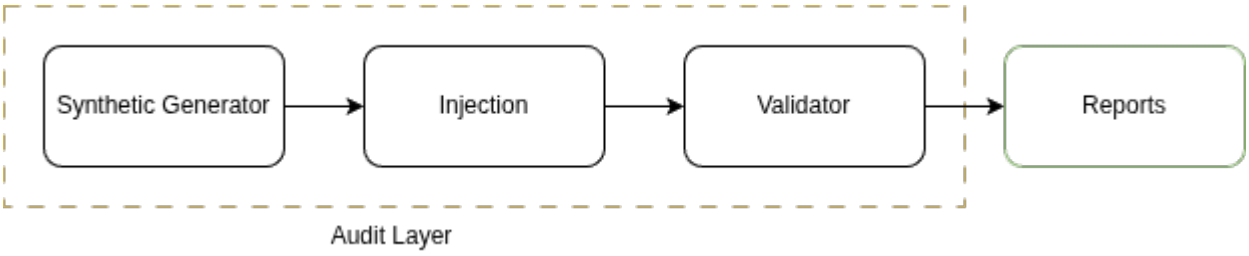

- **Synthetic Generator:** Encargado de generar datasets sintéticos de clientes bajo un contrato de datos definido.
- **Injection:** Introduce errores controlados en el dataset generado (schema, domain, duplicados y reglas de negocio).
- **Validator:** Validar los datos generados contra el contrato de datos, clasificando errores y generando métricas de calidad.

- **Reports:** Genera reportes, métricas de cumplimiento, trazabilidad de reglas aplicadas y logs estructurados de ejecución.

5 ARQUITECTURA DE LA SOLUCIÓN

La solución se implementara como un repositorio único organizado en dos módulos principales, correspondiente a los casos de anonimización y generación de datos sintéticos.

```
tdm-challenge/
├── anonymization/
│   ├── data/
│   │   ├── tdm.db
│   │   └── tdm_anonymizer.db
│   ├── input/
│   │   ├── customers.json
│   │   ├── invoices.json
│   │   └── notifications.json
│   ├── logs/
│   ├── output/
│   │   ├── anonymization_report.json
│   │   └── scan_report.json
│   └── src/
│       ├── create_db.py
│       ├── insert_data.py
│       ├── scanner.py
│       └── anonymizer.py
├── docs/
├── shared/
│   ├── config/
│   │   └── config.yaml
│   └── utils/
│       ├── config.py
│       └── logging.py
├── synthetic_data/
│   ├── data/
│   │   ├── data_injection.json
│   │   └── tdm_synthetic_data.db
│   ├── logs/
│   ├── output/
│   │   ├── clientes_yyyymmdd_hhmm_seednn.json
│   │   ├── errors_yyyymmdd_hhmm_seednn.csv
│   │   ├── errors_yyyymmdd_hhmm_seednn.json
│   │   ├── report_yyyymmdd_hhmm_seednn.json
│   │   └── report_injection.json
│   └── src/
│       ├── generator.py
│       ├── injector.py
│       └── validator.py
├── requirements.txt
└── README.md
```

anonymization

- Escaneo de datos sensibles
- Clasificación por probabilidad
- Anonimización determinística
- Generación de outputs anonimizados

synthetic_data

- Generación de datos sintéticos
- Inyección de fallas
- Validación contra contrato de datos
- Generación de reportes

shared

- Configuración externa (JSON)
- Funciones utilitarias comunes

docs

- Contiene la documentación del diseño de solución, incluyendo arquitectura, decisiones técnicas y consideraciones del sistema.

README.md

- Describe la instalación, ejecución y estructura del proyecto.

6 DECISIONES TÉCNICA

Lenguaje

- Python
- faker
- logging
- json/yaml para configuración

Detección de PII

- Muestreo por columna
- Regex
- Validadores específicos
- Score/probabilidad por tipo

Umbral

- Probabilidad ≥ 90%, anonimizar

Anonimización determinística

- Cédula: transformación determinística preservando longitud y validez
- Teléfono: generación determinística de 10 dígitos
- Email: reconstrucción determinística con formato válido

Integridad referencial

- Misma semilla por entidad/columna
- Misma función para PK/FK relacionadas

Configuración externa

- Reglas fuera del código para facilitar mantenimiento.
- Ingesta de datos externa.
- Parametrización externa.

7 ESTRUCTURA DE DATOS

La tabla sintética se recrea en base a la definición del negocio.

Estructura

- nombre del campo
- tipo
- obligatorio
- regla
- ejemplo

cid	name	type	notnull	dflt_value	pk
0	customer_id	TEXT	0		1
1	nombre	TEXT	1		0
2	apellido	TEXT	1		0
3	cedula	TEXT	1		0
4	fecha_nacimiento	TEXT	1		0
5	email	TEXT	0		0
6	direccion	TEXT	0		0
7	telefono	TEXT	0		0
8	fecha_creacion	TEXT	0		0
9	estado_cliente	TEXT	1		0

customer_id	nombre	apellido	cedula	fecha_nacimiento	email	direccion	telefono	fecha_creacion	estado_cliente
Cus001	Feliciana	Cantón	551819600	08-12-2004	feliciana.cantón@test.com	Urbanización Emilio Calatayud 719 Apt.	913389083	15/08/25 03:15	Activo
Cus002	Eligia	Amor	116542358	17-09-1979	eligia.amor@test.com	Pasaje Dolores Lobo 3 Puerta 6 Cuenca	916155940	29/02/24 01:15	Inactivo
Cus003	Ildefonso	Navarro	1829593100	11-03-1940	ildefonso.navarro@demo.ec	Vía de Plinio Núñez 840 Jaén, 06164	934131647	02/10/24 08:30	Inactivo
Cus004	Carmina	Marcos	2221928324	25-10-1987	carmina.marcos@mail.com	Calle Gisela Goñi 41 Jaén, 19217	964835030	26/10/24 03:45	Inactivo
Cus005	Wilfredo	Patiño	1955376726	23-12-1956	wilfredo.patiño@mail.com	Glorieta de Herminia Lasa 3 Puerta 3 Ll	923884969	18/08/25 03:42	Inactivo
Cus006	Julián	Gimenez	1600122699	16-01-1962	julián.gimenez@test.com	Calle Noa Moles 24 Ourense, 48049	966978480	04/06/25 16:49	Inactivo
Cus007	Maxi	García	1104627045	29-12-1939	maxi.garcia@demo.ec	Vial de Juan Manuel Chaparro 98 Piso 9	928148932	24/02/24 12:02	Activo
Cus008	Porfirio	Gimenez	145701546	30-07-1987	porfirio.gimenez@test.com	Calle Rosalinda Canals 72 Puerta 1 Jaé	903911718	18/08/23 16:04	Inactivo
Cus009	Adelina	Ángel	628963837	29-05-1991	adelina.ángel@demo.ec	Paseo Maricela Lasa 51 Cáceres, 30735	946578713	21/12/24 15:21	Activo
Cus010	Abraham	Lago	1819301035	07-11-1999	abraham.lago@test.com	Pasadizo de Emelina Flor 35 Pontevedra	905183473	31/03/26 13:57	Activo
Cus011	Amaya	Aliaga	1411165663	08-01-1948	amaya.aliaga@mail.com	Urbanización de Bautista Hernando 811	901065133	08/02/24 18:09	Activo
Cus012	Carmela	Dalmau	627317811	27-09-1939	carmela.dalmau@test.com	Paseo Marisol Font 66 Piso 8 Baleares,	980132677	29/11/25 20:01	Activo
Cus013	Jafet	Baró	134746874	09-04-1957	jafet.baró@test.com	Camino Isidro Aguilar 1 Asturias, 03058	934309805	04/11/25 21:35	Activo
Cus014	Rosalina	Murillo	1710812197	03-07-2001	rosalina.murillo@test.com	Cuesta de Iker Catalán 497 Zaragoza, 2	936193990	19/12/24 17:04	Activo

8 REGLAS DE NEGOCIO Y VALIDACIÓN

Schema

- Tipo incorrecto
- Formato incorrecto

Domain

- Estado fuera de Activo/Inactivo

Duplicate

- customer_id repetido

Business

- edad < 18

- inactivo con fecha_creacion menor a 6 meses
- email inválido
- nulls en campos obligatorios

9 ESTRATEGIA DE INYECCIÓN DE FALLAS

Se aplica las siguientes reglas

- scheme: convertir fecha a texto invalido
- domain: estado_cliente = “Suspendido”
- dup: repetir customer_id
- business: edad menor a 18

El porcentaje de error a inyectar es parametrizable en el proceso

10 CONCLUSIONES

La solución propuesta cubre detección de datos sensibles, anonimización determinística preservando formato e integridad relacional, y generación/validación de datos sintéticos con trazabilidad. Además, fue diseñada de forma modular, configurable e idempotente para facilitar su mantenimiento y evolución.